

Social Recommendation with Optimal Limited Attention 阅读报告

背景

作为一个热门的研究课题，推荐系统无疑受到了学术界和业界的广泛关注。但传统的推荐系统存在 *数据稀疏性* 和 *冷启动* 的问题，导致模型的性能下降。于是，**社会化推荐(Social Recommendation)**就被提出，并通过用户之间的社会关系(如好友)来缓解上述两个问题。

然而，大多数现有的方法都不考虑注意力因素造成的限制，即由于人脑的注意力有限(**Limited Attention**)，人们只能接受有限数量的信息，这已经被社会科学视为人类内在的生理特性。事实上，在社交网络中人们很容易就能建立联系，以至于一些在线下比较陌生的人，在线上也能成为好友。这意味着用户之间的社会关系中存在许多噪声和无用的信息。

因此，作者认为对于单个用户的社会化推荐中，不应考虑其所有好友对其的影响。而应该为每个用户选择最优好友子集，使这些好友的偏好能够最好地影响目标用户。

主要工作

- 作者将机器学习技术与社会科学概念相结合，并形式化了社会化推荐中的最优有限关注问题。
- 作者提出了一种新的算法，能够有效地为每个目标用户选择一组社会联系（好友），使得这些被选中好友的偏好最能影响目标用户。然后学习目标用户对这些被选中好友的最优关注(optimal attentions)。

相关研究

- Kang 等人首先提出在推荐系统中考虑 limited attention，但他们只是在所有的社会关系上简单地增加非零权重，无法模拟现实世界的场景，即注意力有限的人只考虑少数朋友的信息。
- 此外，现有的工作中大多使用皮尔森相关系数来计算用户之间的相似性。作者举例说明了这种方法的缺陷。

全局符号

Notations	Description
\mathbf{R}	Rating matrix
\mathbf{U}	User latent features matrix
\mathbf{V}	Item latent features matrix
M	The number of users
N	The number of items
$F(i)$	The set of user i 's friends
d	$\mathbf{U} \in \mathbb{R}^{d \times M}, \mathbf{V} \in \mathbb{R}^{d \times N}$

问题定义：Optimal Limited Attention (OLA)

作者将OLA问题定义为：

- 输入：
 1. 一组用户
 2. 用户之间的社交连接信息
 3. 一组项目
 4. 用户-项目评级子集
- 输出（对于每个目标用户）：
 1. 一个最优好友子集，使得这个子集中的好友的偏好可以最好地影响目标用户
 2. 针对最优好友子集中的每一个用户，学习目标用户对其的最佳的注意力/注意程度(optimal attention)

算法：OLA-Rec(Social Recommendation with Optimal Limited Attention)

首先，为每一个目标用户 i 引入一个向量 $\phi_i \in \mathbb{R}^{d \times 1}$ ，视为用户 i 的好友对其偏好产生的影响的聚合：

$$\phi_i = \sum_{u \in F(i)} \alpha_{iu} \mathbf{U}_u \quad (1)$$

其中， α_{iu} 为 i 对 u 的注意力，且满足 $\alpha_{iu} \geq 0$, $\sum_{u=1}^{|F(i)|} \alpha_{iu} = 1$. 这里 (1) 应该是指最优的情况，因为作者接着提出了最小化绝对值：

$$\begin{aligned} \min_{\alpha_i} \quad & \left| \sum_{u \in F(i)} \alpha_{iu} \mathbf{U}_u - \phi_i \right| \\ \text{s.t.} \quad & \alpha_{iu} \geq 0, \\ & \sum_{u=1}^{|F(i)|} \alpha_{iu} = 1 \end{aligned} \quad (2)$$

然后作者通过变换找到了 (2) 的上界：

$$\begin{aligned} \left| \sum_{u \in F(i)} \alpha_{iu} \mathbf{U}_u - \phi_i \right| &\leq C \|\alpha_i\|_2 + L \sum_{u \in F(i)} \alpha_{iu} d(\mathbf{U}_u, \mathbf{U}_i) \\ \Leftrightarrow \left| \sum_{u \in F(i)} \alpha_{iu} \mathbf{U}_u - \phi_i \right| &\leq C (\|\alpha_i\|_2 + \alpha_i^T \beta_i) \end{aligned} \quad (3)$$

其中 C 和 L 为常数， $\beta_i \in \mathbb{R}^{|F(i)|}$ ，且：

$$\beta_{iu} = L \cdot d(\mathbf{U}_u, \mathbf{U}_i) / C$$

$d(\cdot, \cdot)$ 为欧氏距离， $L_c = \frac{L}{C}$ 为超参。同时规定 $u \in F(i)$ 按照 $d(\mathbf{U}_u, \mathbf{U}_i)$ 升序排列，即与 i 离得近的 u 排在前面。

于是最小化 (2) 变为最小化它的上界：

$$\begin{aligned} \min_{\alpha_i} \quad & C (\|\alpha_i\|_2 + \alpha_i^T \beta_i) \\ \text{s.t.} \quad & \alpha_{iu} \geq 0 \\ & \sum_{u=1}^{|F(i)|} \alpha_{iu} = 1 \end{aligned} \quad (4)$$

应用拉格朗日乘数法：

$$L(\alpha_i, \lambda, \theta) = \|\alpha_i\|_2 + \alpha_i^T \beta_i + \lambda(1 - \sum_{u=1}^{|F(i)|} \alpha_{iu}) - \sum_{u=1}^{|F(i)|} \theta_{iu} \alpha_{iu} \quad (5)$$

对 α_i 求偏导数，并置为0：

$$\frac{\partial L}{\partial \alpha_{iu}} = \alpha_{iu} - \|\alpha\|_2 \times (\lambda - \beta_{iu} + \theta_{iu}) = 0$$

$$\frac{\alpha_{iu}}{\|\alpha_i\|_2} = \lambda - \beta_{iu} + \theta_{iu}$$

根据KKT条件： $\forall \alpha_{iu} > 0, \theta_{iu} = 0$ (即 $\beta_{iu} < \lambda$) 以及 $\forall \alpha_{iu} > 0, \theta_{iu} \geq 0$ (即 $\beta_{iu} \geq \lambda$)。

因此对任意的最优解 $\alpha_{iu}^* > 0$:

$$\frac{\alpha_{iu}^*}{\|\alpha_i^*\|_2} = \lambda - \beta_{iu} \quad (6)$$

考虑到 $\sum_{u=1}^{|F(i)|} \alpha_{iu} = 1$, 任意 $\alpha_{iu}^* > 0$ 可以如下计算:

$$\alpha_{iu} = \frac{\lambda - \beta_{iu}}{\sum_{\alpha_{iu} > 0} (\lambda - \beta_{iu})} \quad (7)$$

由于 $\beta_i = (\beta_{i1}, \dots, \beta_{iu}, \dots, \beta_{i|F(i)|})^T$ 是按照 $d(U_u, U_i)$ **升序** 排列的, 故 α_{iu} 是**降序**排列的, 因此:
 $\exists k_i^*, 1 \leq k_i^* \leq |F(i)|$ 使得 $\forall u > k_i^*, \alpha_{iu}^* = 0$ 且 $\forall u \leq k_i^*, \alpha_{iu}^* > 0$. 这里的 k_i^* 就是用户 i 最优好友子集的基数。

- 计算 α_i

(6)的两边平方和:

$$\sum_{\alpha_{iu}^* > 0} \frac{(\alpha_{iu}^*)^2}{\|\alpha_i^*\|_2^2} = \sum_{\alpha_{iu}^* > 0} (\lambda - \beta_{iu})^2 = 1 \quad (8)$$

将(8)展开得:

$$k_i^* \lambda^2 - 2\lambda \sum_{u=1}^{k_i^*} \beta_{iu} + \left(\sum_{u=1}^{k_i^*} \beta_{iu}^2 - 1 \right) = 0 \quad (9)$$

$$\lambda = \frac{1}{k_i^*} \left(\sum_{u=1}^{k_i^*} \beta_{iu} + \sqrt{k_i^* + \left(\sum_{u=1}^{k_i^*} \beta_{iu} \right)^2 - k_i^* \sum_{u=1}^{k_i^*} \beta_{iu}^2} \right) \quad (10)$$

因此, 给定 k_i^* , 可以将 (10) 中的 λ 代入 (7) 得到 α_i^* .

- 计算 k_i^*

作者提出了一种简单的算法计算 k_i^* , 即从 1 开始升序遍历 k_i , 直到满足条件的最大的 k_i 为止:

Algorithm 1 Optimal Limited Attention

Require: target user i , i 's social connections (friends) $u \in F(i)$, $\beta_{iu} \in \mathbb{R}$ sorted in ascending order.

Initialization: $\lambda_0 = \beta_{i,1} + 1$, $k = 0$

while $\lambda_k > \beta_{i,k+1}$ and $k \leq |F(i)|$ **do**

$k \leftarrow k + 1$

end while

return k and α_i (whose u -th element $\alpha_{iu} = \frac{\lambda_k - \beta_{iu}}{\sum_{\alpha_{iu} > 0} (\lambda_k - \beta_{iu})}$);

(不过这里有一个问题就是, 作者并没有证明 λ_k 是随 k 递增的, 那么最后一次循环的结果难道不会出现 $\lambda_k < \lambda_{k-1}$ 的情况吗?)

- Objective Function 和 EM style optimization strategy

将所有的优化目标组合在一起得到损失函数：

$$\begin{aligned}
 \mathcal{L} = \min & \left[\frac{1}{2} \sum_{i=1}^M \sum_{j=1}^N I_{ij}^R (R_{ij} - \phi_i^T V_j)^2 \right. \\
 & + \frac{\delta_\phi}{2} \sum_{i=1}^M \left(\phi_i - \sum_{u \in F(i)_{k^*}} \alpha_{iu}^* U_u \right)^T \left(\phi_i - \sum_{u \in F(i)_{k^*}} \alpha_{iu}^* U_u \right) \\
 & + \frac{\delta_\phi}{2} \sum_{i=1}^M (U_i - \phi_i)^T (U_i - \phi_i) \\
 & \left. + \frac{\delta_U}{2} \sum_{i=1}^M U_i^T U_i + \frac{\delta_V}{2} \sum_{j=1}^N V_j^T V_j \right], \quad (
 \end{aligned}$$

最后作者提出使用 EM style的优化策略，即先通过算法1计算 k^* 和 α^* ，再通过SGD对目标函数进行优化。